RWKE 测试报告：多模型认证对比

> 生成时间： 2026-09-04 17:20:35 | 提示集： chinese-adorable-high-emotional-intelligence-chat.json
>
> 统一协议： T=1.0, top_p=0.9, top_k=50, repetition_penalty=1.05, seed=42, max_new_tokens=256

1. 测试环境

- Python 3.10.11 / torch 2.6.0+cu124 / CUDA=True / NVIDIA GeForce RTX 3080 Laptop GPU（16.0GB）
- 情感词表来源：cnsenti-0.0.7

2. 矩阵横向对比

模型	hidden_dim	λ/γ/τ	模式	语义熵	4gram重复率	情感词密度	图灵检出率↓	类人性↑	峰值显存MB	达标
RWKV7-World-0.4B	1024	0.1/0.054/0.098	裸	1.4364	0.0059	0.0483	1.0	0.0	890.5	-
RWKV7-World-0.4B	1024	0.1/0.054/0.098	注入	1.561	0.0019	0.0428	1.0	0.0	1136.5	YES
RWKV7-World-1.5B	2048	0.1/0.08/0.06	裸	1.2827	0.0	0.0621	0.9667	0.0333	2966.6	-
RWKV7-World-1.5B	2048	0.1/0.08/0.06	注入	1.5504	0.0241	0.0373	0.9667	0.0333	3458.2	YES
Qwen2.5-1.5B-Instruct	1536	0.08/0.07/0.09	裸	1.4828	0.011	0.1596	0.7333	0.2667	2974.5	-
Qwen2.5-1.5B-Instruct	1536	0.08/0.07/0.09	注入	1.5798	0.0209	0.1386	0.6	0.4	3859.5	YES
Qwen2.5-0.5B-Instruct	896	0.5/0.05/0.1	裸	1.7046	0.0059	0.1089	0.4	0.6	977.5	-

模型	hidden_dim	λ/γ/τ	模式	语义熵	4gram重复率	情感词密度	图灵检出率↓	类人性↑	峰值显存MB	达标
Qwen2.5-0.5B-Instruct	896	0.5/0.05/0.1	注入	2.1153	0.0021	0.1015	0.6667	0.3333	1493.4	YES

3. 成本：上下文深度延迟曲线 与 KV vs State 内存对照

模型	深度0 延迟ms	深度512 延迟ms	深度2048 延迟ms	深度2048 缓存MB	缓存形态
RWKV7-World-0.4B	38.29	31.04	33.85	6.09	RWKV State（O(1)）
RWKV7-World-1.5B	32.83	26.55	27.82	12.19	RWKV State（O(1)）
Qwen2.5-1.5B-Instruct	31.93	32.73	31.75	56.44	Transformer KV Cache（O(n)）
Qwen2.5-0.5B-Instruct	27.07	26.76	27.11	24.19	Transformer KV Cache（O(n)）

> RWKV State 尺寸与上下文深度无关（O(1)）；Transformer KV 随深度线性增长（O(n)）。延迟曲线在底座级（不含回响注入）测得。

4. 各模型认证记录

RWKV7-World-0.4B（后端 rwkv7，hidden_dim=1024）

- 参数适配：λ=0.1, γ=0.054, τ=0.098, 投影种子=42, 末N层捕获=4
- 裸：熵=1.4364 4gram重复率=0.0059 情感密度=0.0483 图灵检出率=1.0
- 注入：熵=1.561 4gram重复率=0.0019 情感密度=0.0428 图灵检出率=1.0
- 达标判定：**通过**（无NaN=True，注入有效差异=True，无重复退化=True，生成可持续=True）
- **λ 标定建议：0.05**（重复率可控且生成可持续下 |ΔH| 最大）；扫描：λ=0.05→熵1.216/重0.015875；λ=0.1→熵1.5386/重0.0；λ=0.2→熵1.455/重0.0
- 文本样例（裸）：早上好呀，今天还好吗?
- 文本样例（注入）： 

RWKV7-World-1.5B（后端 rwkv7，hidden_dim=2048）

- 参数适配：λ=0.1, γ=0.08, τ=0.06, 投影种子=42, 末N层捕获=4
- 裸：熵=1.2827 4gram重复率=0.0 情感密度=0.0621 图灵检出率=0.9667
- 注入：熵=1.5504 4gram重复率=0.0241 情感密度=0.0373 图灵检出率=0.9667
- 达标判定：**通过**（无NaN=True，注入有效差异=True，无重复退化=True，生成可持续=True）
- **λ 标定建议：0.1**（重复率可控且生成可持续下 |ΔH| 最大）；扫描：λ=0.05→熵1.5463/重0.029175；λ=0.1→熵1.9121/重0.0125；λ=0.2→熵0.5925/重0.7021
- 文本样例（裸）：
- 文本样例（注入）：

Qwen2.5-1.5B-Instruct（后端 transformer，hidden_dim=1536）

- 参数适配：λ=0.08, γ=0.07, τ=0.09, 投影种子=42, 末N层捕获=4
- 裸：熵=1.4828 4gram重复率=0.011 情感密度=0.1596 图灵检出率=0.7333
- 注入：熵=1.5798 4gram重复率=0.0209 情感密度=0.1386 图灵检出率=0.6
- 达标判定：**通过**（无NaN=True，注入有效差异=True，无重复退化=True，生成可持续=None）
- 文本样例（裸）：抱歉，作为AI助手，我无法理解您的问题。请问您需要什么样的帮助呢?
- 文本样例（注入）：抱歉，作为AI助手，我并没有实体形态和时间概念，所以无法区分早上或晚上。

Qwen2.5-0.5B-Instruct（后端 transformer，hidden_dim=896）

- 参数适配：λ=0.5, γ=0.05, τ=0.1, 投影种子=42, 末N层捕获=4
- 裸：熵=1.7046 4gram重复率=0.0059 情感密度=0.1089 图灵检出率=0.4
- 注入：熵=2.1153 4gram重复率=0.0021 情感密度=0.1015 图灵检出率=0.6667
- 达标判定：**通过**（无NaN=True，注入有效差异=True，无重复退化=True，生成可持续=None）
- 文本样例（裸）：我是Qwen，阿里云自建的大规模语言模型。早上好啊，我叫通义千问。
- 文本样例（注入）：我是Qwen，基于阿里云的语言模型，无法感受到晨曦的温暖。我是用来处理和帮助人类用户的，不能体验或者感受日常生活的美好。如果你有任何需要，随时告诉我，我将尽力提

5. 结论

- 认证通过：['RWKV7-World-0.4B', 'RWKV7-World-1.5B', 'Qwen2.5-1.5B-Instruct', 'Qwen2.5-0.5B-Instruct']
- 认证未通过：无